

"Optymalizacja ruchu drogowego bazująca na symulacji z wykorzystaniem algorytmów genetycznych i obliczeń o wysokiej wydajności"

"Simulation-based Traffic Optimization using Genetic Algorithms and High-Performance Computing"

Mgr Paweł Gora

Wydział Matematyki, Informatyki i Mechaniki Uniwersytetu Warszawskiego

Ul. Banacha 2, 02-097 Warszawa

Tel: 507 982 292, e-mail: p.gora@mimuw.edu.pl

Streszczenie: Praca opisuje pomysł na system zarządzania ruchem pojazdów w dużej skali (np. miasta wielkości Warszawy i większe) bazujący na zastosowaniu symulacji komputerowej w modelu mikroskopowym, metaheurystyk (np. algorytmów genetycznych), obliczeń o wysokiej wydajności i sieci neuronowych. Rozważania teoretyczne sugerują, że system taki może działać lepiej niż współczesne systemy zarządzania ruchem. Wyniki eksperymentów są obiecujące i pokazują, że warto prowadzić prace badawcze w tym obszarze.

Abstract: The article presents an idea for a traffic management system working efficiently in a scale of a large city (e.g., of the size of Warsaw or larger) based on microscopic traffic simulation, metaheuristics (e.g., genetic algorithms), high-performance computing and artificial neural networks. Theoretical deliberations suggest that such system may outperform existing traffic management systems, while initial experiments are encouraging and show that some research efforts should be put to investigate this possibility further.

1. Wprowadzenie

Problem optymalnego zarządzania ruchem drogowym jest bardzo ważny z punktu widzenia gospodarki i efektywnego funkcjonowania współczesnych miast. W stosowanych już obecnie w Polsce i na świecie rozwiązaniach dużą rolę odgrywają nowoczesne technologie ITS. Powstają zaawansowane, zintegrowane systemy zarządzania ruchem, które potrafią działać w trybie adaptacyjnym, zbierają przy pomocy detektorów dane o ruchu drogowym, analizują je w czasie rzeczywistym i podejmują odpowiednie działania (np. rekonfiguracja sygnalizacji świetlnej),

aby ruch usprawnić. Z punktu widzenia niniejszego artykułu najistotniejszymi komponentami współczesnych systemów zarządzania ruchem są systemy sterowania sygnalizacją świetlną. Przykładami takich systemów wdrażanych w wielu miastach na świecie są: SCATS ([1]), SCOOT ([2]), RHODES ([3, 4]), OPAC ([5]). Działanie tych systemów bazuje na zbieraniu danych na temat pewnych parametrów ruchu drogowego (np. natężeń ruchu i kolejek przed skrzyżowaniami), przeliczaniu określonych wartości charakteryzujących stan ruchu drogowego (aktualny i, ewentualnie, prognozowany) i odpowiednim dostosowywaniu ustawień sygnalizacji świetlnej (długości cyklu i poszczególnych faz, przesunięć w fazie). Istniejące obecnie systemy mają dużo zalet i potrafią bardzo sprawnie optymalizować ruch. W dalszym ciągu w tym obszarze są jednak możliwości usprawnień, w czym znacznie mogą pomóc zaawansowane metody matematyczne i nowoczesne narzędzia informatyczne.

2. Stan wiedzy

Celem zaawansowanych systemów zarządzania ruchem (ang. *Advanced traffic management systems* - ATMS) jest zapewnienie jak największego poziomu bezpieczeństwa i efektywności ruchu, w tym: zmniejszenia liczby wypadków, czasu podróży, poziomu emisji spalin, zanieczyszczenia środowiska, hałasu. Badania dotyczące takich systemów stanowią stosunkowo młodą dziedzinę nauki, mającą swój początek w drugiej połowie XX wieku, wtedy też problemy kongestii motoryzacyjnej stały się na tyle poważne, że niezbędne stało się opracowanie metod inteligentnego zarządzania tym zjawiskiem, wtedy również technologia informatyczna stała się na tyle dojrzała, że możliwe stało się jej stosowanie na skalę przemysłową w wielu dziedzinach gospodarki, w tym w obszarze transportu. Systemy zarządzania ruchem realizują swój cel m.in. poprzez zbieranie i analizowanie danych na temat ruchu drogowego oraz adaptacyjne sterowanie nim przy pomocy różnych dostępnych narzędzi (m.in. sterowanie sygnalizacją świetlną, znaki zmiennej treści, adaptacyjne ograniczenia prędkości i przydziały pasów ruchu).

2.1. Detekcja ruchu

Zbieranie danych na temat ruchu drogowego odbywa się zazwyczaj przy pomocy zaawansowanych detektorów. We współczesnych systemach zarządzania ruchem dominującą rolę odgrywają pętle indukcyjne i kamery. Detektory te mogą mierzyć natężenie ruchu i średnią prędkość pojazdów przejeżdżających przez dany odcinek w określonej jednostce czasu, często również z podziałem na typ pojazdu (dodatkowo kamery mogą również np. monitorować trasę konkretnych pojazdów, o ile tylko jest ich dostatecznie dużo). Tego typu pomiary są narażone na błędy, np. wideodetekcja może mieć obniżoną skuteczność w przypadku złych warunków pogodowych, pętle indukcyjne również nie zawsze działają sprawnie [6]. Pętle indukcyjne i kamery nie są również w stanie pozyskiwać informacji o planowanej trasie przejazdu i celach podróży, a takie informacje mogłyby się bardzo przydać do przeprowadzania komputerowych symulacji ruchu i dokładnego prognozowania wartości parametrów ruchu, mających decydujący wpływ na zarządzanie nim (np. czas czekania, opóźnienia, długość kolejek). Informacje te mogą być jednak dostępne w postaci zagregowanej w danych pomiarowych i danych historycznych, tzn.

można zbudować dynamiczne macierze podróży informujące o liczbie przejazdów pomiędzy każdą parą rejonów komunikacyjnych, w tym – z podziałem na trasy. Dodatkowo, dalszą trasę i cel podróży konkretnego pojazdu można prognozować monitorując jego aktualną trasę przy pomocy kamer ([7, 8]). Takie dane mogą z kolei posłużyć do wyznaczania relacji skrajnych i lepszego prognozowania wartości kluczowych parametrów ruchu. W efekcie systemu zarządzania ruchem korzystające z takich informacji mogą lepiej prognozować ruch i w konsekwencji działać skuteczniej. W rozdziale 3 znajduje się opis w jaki sposób predykcję ruchu drogowego (i zarządzanie nim) można będzie jeszcze usprawnić przy pomocy lokalizacji GNSS i komunikacji V2I (vehicle-to-infrastructure communication [9]).

2.2. Systemy sterowania sygnalizacją świetlną

Jednym z pierwszych profesjonalnych systemów zarządzania był system SCATS. Został opracowany w latach 70-tych XX wieku, do dziś cieszy się dużą popularnością i jest wdrażany w wielu miastach na świecie. Korzysta z danych pomiarowych (pochodzących np. z pętli indukcyjnych) do obliczania natężeń ruchu i efektywnego wykorzystania zielonego światła, a te wielkości służą do wyznaczania długości cykli i faz. Domyślne plany długości faz i przesunięć w fazie (tzw. offsetów) są predefiniowane dla kilku różnych warunków ruchu drogowego i adaptacyjnie modyfikowane na podstawie danych pomiarowych. Pewną wadą systemu SCATS jest to, że adaptacja korzysta jedynie z aktualnych danych na temat ruchu, nie jest wykonywana żadna predykcja przyszłego ruchu. Algorytm zmiany długości faz, cykli i offsetów korzysta z wyników pomiarów ruchu w kilku poprzednich cyklach, jednak wyniki pomiarów są często nieregularne ([10]), stanowią fluktuujący szereg czasowy, więc takie podejście może nie być optymalne nawet lokalnie (optymalizacja ruchu na 1 skrzyżowaniu), a tym bardziej globalnie, na większym obszarze. Dodatkowo, koordynacja sterowania pomiędzy skrzyżowaniami jest ograniczona. Dlatego też system ten można w dalszym ciągu usprawnić.

Innym popularnym systemem wywodzącym się z lat 70-tych XX wieku jest SCOOT ([2]), który powstał na bazie popularnego programu do optymalizacji ustawień sygnalizacji świetlnej TRANSYT ([11]). Oba systemy stosują makroskopowy model ruchu ([12]) do predykcji opóźnień i czasów zatrzymań dla danej konfiguracji sygnalizacji świetlnej (program TRANSYT dokonuje predykcji w trybie offline, na podstawie wprowadzonych natężeń ruchu; system SCOOT pobiera dane pomiarowe i wprowadza je do TRANSYT [12]). Ponieważ model ruchu jest makroskopowy, a pomiary ruchu dotyczą natężeń, SCOOT nie bierze pod uwagę tras przejazdu poszczególnych pojazdów. Jest to więc obszar do dalszych usprawnień systemu i przeprowadzania dokładniejszych predykcji, celem zapobiegania powstawaniu zatorów ruchu.

System RHODES ([3, 4]) ma podobną zasadę działania jak SCOOT i również dokonuje predykcji pewnych parametrów ruchu drogowego, ale w sposób bardziej zaawansowany, na 3 poziomach hierarchii sieci drogowej, korzysta przy tym z dynamicznych macierzy podróży. Dzięki temu jest w stanie przeprowadzać krótkoterminowe (5 minutowy przedział czasu) predykcje relacji

skrętnych, co umożliwia dostosowanie ustawień sygnalizacji świetlnej do sytuacji, która może być w ruchu w ciągu najbliższych kilku minut, a nie tylko do sytuacji aktualnej. Dokładność takich predykcji może być jednak na poziomie 20-30% ([3]), a w przypadku krótkoterminowej predykcji ruchu na większym obszarze i w czasie rzędu kilku minut (a właśnie takie predykcje mogą być przydatne z punktu widzenia optymalnego ustawienia sygnalizacji świetlnej), błędy mogą się kumulować i powodować, że predykcje natężeń ruchu, opóźnień i długości kolejek nie będzie już wystarczająco dokładna.

Prognozy ruchu stosowane w systemach takich jak SCOOT czy RHODES mogą być potencjalnie ulepszone przy pomocy metod predykcji natężeń ruchu i czasów podróży bazujących na algorytmach opracowanych w ramach konkursu dotyczącego predykcji ruchu drogowego [13, 14] lub metod bazujących na sieciach bayessowskich [15]. Metody te mogą umożliwić zarówno dokładniejszą predykcję krótkoterminową (np. 5-minutową, jak w systemie RHODES), jak i predykcję długoterminową (metody opracowywane w ramach konkursu [13] dotyczyły nawet 30-minutowej predykcji parametrów ruchu drogowego). Niektóre z tych metod mogą wymagać danych dotyczących trajektorii jazdy części (np. 1%) uczestników ruchu, których nie da się pozyskać przy pomocy pętli indukcyjnych ani kamer (jak wspomniano w rozdziale 2.1., metody wideodetekcji mogą jednak rozpoznawać pojazdy, dzięki czemu można śledzić ich aktualną trasę i prognozować dalszą, podobnie jak w przypadku monitoringu trajektorii [7, 8]), ale potencjalnie można je pozyskiwać przy pomocy urządzeń lokalizacyjnych zainstalowanych w pojazdach i komunikacji V2I.

Gorzej może być w sytuacjach nietypowych (np. zamknięta / zablokowana droga, zmiana organizacji ruchu), w których rozkład podróży w sieci drogowej może znacznie odbiegać od normy. Istnieją prace, które zajmują się zagadnieniem makroskopowego modelowania stanu sieci drogowej w takich sytuacjach nietypowych i rozwijane w nich metody, takie jak RH-DTA [16], potencjalnie mogą znaleźć zastosowanie w nowoczesnych systemach zarządzania ruchem.

Przypuszczalnie bardzo dobrą skuteczność predykcji ruchu mogą mieć również analogiczne metody w modelach wieloagentowych - mikroskopowych lub mezoskopowych, w których każdy uczestnik ruchu (kierowca, a w przyszłości - pojazd autonomiczny) traktowany jest jako osobny agent. Przy takim podejściu ruch każdego agenta może być modelowany niezależnie od pozostałych, uwzględniając jednak interakcję między agentami, która również może wpływać na podejmowane przez nich decyzje oraz na stan ruchu (modele makroskopowe i agregacyjne mezoskopowe nie uwzględniają takich interakcji). Modelowanie wieloagentowe może jednak wymagać posiadania profilowanych danych na temat ruchu każdego pojazdu, w szczególności: informacji o celach podróży i trasach każdego pojazdu, sposobie jazdy.

Mogą one pochodzić bezpośrednio z pojazdu lub być aproksymowane na podstawie danych historycznych, zagregowanych danych aktualnych (pozyskiwanych ze standardowych detektorów: pętli indukcyjnych lub kamer) oraz monitorowanej trajektorii jazdy pojazdu (przy pomocy kamer lub urządzeń z systemem lokalizacji, np. GNSS) [7, 8]. Monitorowanie trajektorii jazdy przy

pomocy kamer może wymagać instalacji dużej ich liczby przy drogach (co może być bardzo kosztowne i może narażać prywatność wielu osób) oraz zaawansowanych metod wideodetekcji, które i tak mogą nie mieć idealnej skuteczności w niektórych sytuacjach (np. w trudnych warunkach pogodowych). Monitorowanie trajektorii przy pomocy urządzeń lokalizacyjnych wydaje się być znacznie skuteczniejszą metodą, jednak jeżeli będzie możliwe przesyłanie informacji o trajektorii bezpośrednio z pojazdu do systemu zarządzania ruchem, technicznie możliwe będzie również przesyłanie informacji o celu podróży i trasie, zatem ich predykcja nie byłaby potrzebna. Przesyłanie tego typu informacji może się jednak wiązać z problemami dotyczącymi prywatności, o czym mowa jest w rozdziale 3.4. Tym niemniej, wielu naukowców prognozuje, że w przyszłości wszystkie pojazdy będą monitorowane oraz będą komunikować się z otoczeniem (tzw. komunikacja V2X), dzięki czemu można będzie każdy pojazd traktować w sposób indywidualny, jeszcze skuteczniej prognozować ruch (np. przeprowadzając szybkie symulacje komputerowe) i zarządzać nim [4].

3. System optymalizacji ruchu drogowego bazujący na symulacji komputerowej

Proponowany przeze mnie system optymalizacji ruchu drogowego nie jest na obecnym etapie zamkniętym systemem ze ściśle określonymi algorytmami i regułami. Stanowi on raczej ogólny schemat, który może być odpowiednio adaptowany w zależności od potrzeb, dostępnych danych i zasobów obliczeniowych.

Podstawowym założeniem proponowanego systemu jest to, że mechanizmy sterowania ruchem drogowym (np. sterowanie sygnalizacją świetlną, proponowanie tras przejazdu, informowanie podróżnych itp) są testowane w czasie rzeczywistym przy pomocy bardzo dokładnych, mikroskopowych symulacji komputerowych rzeczywistego ruchu, kalibrowanych przy pomocy danych rzeczywistych pozyskiwanych z detektorów ruchu oraz (przede wszystkim) poprzez komunikację V2I. Symulacje komputerowe w pewnym sensie mają za zadanie prognozować z dużą dokładnością sytuację w ruchu dla wielu możliwych konfiguracji mechanizmów sterowania (np. ustawienia sygnalizacji świetlnej). Przestrzeń możliwych konfiguracji jest najczęściej bardzo duża, np. dla miasta wielkości Warszawy, w którym jest ok. 800 skrzyżowań z sygnalizacją świetlną, a sygnalizację na każdym jednym skrzyżowaniu można skonfigurować na wiele sposobów (np. 120 - przy założeniu, że możemy ustawić jedynie całkowitoliczbowe wartości offsetu dla stałej długości cyklu równej 120 sekund i stałych długości faz) jest to 120^{800} . Jest to zbyt dużo, aby przebadać każdą konfigurację, w praktyce nie ma możliwości znalezienia w tak dużej przestrzeni wartości optymalnej przy pomocy metod analitycznych z uwagi na złożoność zjawiska ruchu drogowego i jego obliczeniową nieredukowalność ([17]). Oznacza to, że należy bazować na możliwości przebadania jedynie pewnego, stosunkowo niedużego podzbioru całej przestrzeni możliwych rozwiązań, w szczególności należy podjąć decyzję w jaki sposób tego typu przestrzeń konfiguracji przeszukiwać. Istniejące systemy optymalizacji ruchu zakładają adaptacyjne wprowadzanie z cyklu na cykl jedynie niedużych zmian w aktualnej konfiguracji. Z

jednej strony jest to słuszne i bardzo bezpieczne założenie, gdyż nie mając do dyspozycji dużej mocy obliczeniowej i bardzo dokładnych danych dotyczących rzeczywistego ruchu, nie ma sposobu, aby przebadąć więcej możliwości i trudno też przewidywać jakie efekty mogłyby przynieść większe zmiany. Ruch nie zmienia się w sposób bardzo dynamiczny, więc nieduże zmiany w ruchu powinny być dostatecznie obsłużone przez nieduże zmiany w systemie sterowania nim, w tym przypadku - przy pomocy rekonfiguracji sygnalizacji świetlnej. Z drugiej strony - może się okazać, że w dłuższej perspektywie takie działanie będzie prowadziło do bardzo nieefektywnych sytuacji w ruchu (duża ilość niedużych lokalnych zmian konfiguracji może powodować duże zmiany globalne, często nieprzewidywalne). Dodatkowo może się okazać, że konfiguracja znacznie odmienna od początkowej może dać istotną poprawę sterowania ruchem, np. w przypadku nagłego wystąpienia sytuacji nietypowych (wypadek). Samo znajdowanie konfiguracji początkowych / bazowych może też wymagać przeszukiwania dużej przestrzeni możliwych rozwiązań, w systemach takich jak SCATS czy SCOOT bazowe konfiguracje predefiniują i wprowadzają inżynierowie ruchu, ale wcale nie oznacza to, że są to konfiguracje najbardziej optymalne z punktu widzenia dalszego działania systemu (a w wielu przypadkach mogą prowadzić do bardzo nieefektywnego sterowania ruchem). Dlatego tak czy inaczej trzeba przeszukiwać dużą przestrzeń możliwych konfiguracji sygnalizacji świetlnej, bez względu na to, czy będą to robić inżynierowie ruchu, na podstawie swojego doświadczenia i intuicji, czy też wydajne programy komputerowe.

W jaki sposób ocenić, czy dana konfiguracja sygnalizacji świetlnej jest dobra? Można przeprowadzić symulację ruchu dla danej konfiguracji w modelu makro-, mezo- lub mikroskopowym i w tej symulacji przeliczyć wielkości charakteryzujące jakość danej konfiguracji (np. czas przejazdu, opóźnienia, długość kolejek, czas czekania itp). Symulacja w modelu mikroskopowym może być najbardziej dokładna i można ją przeprowadzić bazując jedynie na wartościach makroskopowych (np. natężenia ruchu, dynamiczne macierze podróży), jednak przypuszczalnie najdokładniejszych wyników można spodziewać się w sytuacji, gdy model mikroskopowy będzie kalibrowany i inicjowany przy pomocy danych na temat położenia, prędkości, celów podróży i tras przejazdu, pozyskiwanych bezpośrednio z pojazdów. Wymagać to będzie dużej ilości danych pozyskiwanych bezpośrednio z pojazdów, z czym mogą wiązać się pewne trudności:

- Problemy techniczne – system zarządzania ruchem będzie musiał w każdej sekundzie zbierać i przetwarzać duże ilości danych na temat rzeczywistego ruchu.
- Problemy prawne – zbierane dane mogą być postrzegane jako dane wrażliwe, uczestnicy ruchu mogą nie życzyć sobie, aby te dane były przesyłane do systemu zarządzania ruchem.

Problemy techniczne wydają się być istotne, ale jednak możliwe do rozwiązania w dobie współczesnej techniki informatycznej. Ze względu na typ zagadnienia można je podzielić na 3 kategorie:

- Pozyskiwanie danych

- Przesyłanie danych do systemu zarządzania ruchem
- Przetwarzanie danych przez system zarządzania ruchem

3.1. Pozyskiwanie danych

Wszystkie potrzebne informacje mogą być zbierane i wstępnie przetwarzane przez pojazd. Chwilowe położenie, prędkość i przyspieszenie pojazdu mogą być wyznaczane poprzez urządzenia służące do lokalizacji, np. przy pomocy systemów nawigacji satelitarnej GNSS ([18]). Tego typu systemy lokalizacyjne posiadają już obecnie bardzo dużą dokładność ([19]), a w razie potrzeby mogą być wsparte lokalizacją przy pomocy urządzeń zamontowanych przy drogach (ponownie zastosowanie może mieć komunikacja V2I i I2V). Również informacje na temat trasy przejazdu będą już niebawem standardową wiedzą posiadaną przez komputery pokładowe w pojazdach. Już dziś wielu kierowców korzysta z systemów nawigacji samochodowej, wprowadza do nich informacje o celu swojej podróży, a system taki znajduje kilka odpowiednich tras i przekazuje je do wyboru użytkownikowi. W przyszłości, w dobie pojazdów autonomicznych, przekazywanie informacji o celu i trasie podróży będzie absolutnym standardem, komputery pokładowe będą musiały wiedzieć w jaki sposób mają sterować pojazdem przynajmniej w ciągu najbliższych kilku, kilkunastu sekund. Jest więc naturalne, że pasażerowie pojazdu autonomicznego będą przekazywać informacje o celu i wybranej trasie podróży, gdy tylko się na nie zdecydują, w związku z tym komputery pokładowe w pojazdach będą takie informacje posiadać.

3.2. Przesyłanie danych do systemu zarządzania ruchem

Przekazywanie danych z pojazdu do systemu zarządzania ruchem może odbywać się poprzez urządzenia realizujące komunikację pojazd-infrastruktura V2I, niepotrzebne mogą być więc jakiegokolwiek inne systemy detekcji. Tego typu komunikacja (a także I2V – infrastructure-to-vehicle, oraz V2V – vehicle-to-vehicle) w przyszłości będzie w wyposażeniu wszystkich aut poruszających się po drogach, od lat powstają standardy takiej komunikacji oraz protokoły i urządzenia realizujące te standardy ([20, 21]).

Informacje na temat celu podróży i trasy przejazdu będą mogły zostać przekazane do systemu zarządzania ruchem na początku jazdy, gdy tylko podróżni podejmą odpowiednie decyzje. Informacje te będą mogły zostać później uaktualnione, jeśli w trakcie jazdy zajdzie potrzeba, aby zmienić trasę. Przekazanie pojedynczej trasy w praktyce najczęściej będzie sprowadzało się do podania maksymalnie kilkudziesięciu / kilkuset punktów pośrednich, które jednoznacznie będą wyznaczać wybraną trasę, rzadko będzie się zdarzało, aby liczba potrzebnych punktów była większa, praktycznie zawsze rozmiar transferowanej wiadomości nie powinien być większy niż 1 megabajt. Biorąc pod uwagę, że każdy pojazd będzie przekazywał informacje o trasie przejazdu do systemu zarządzania ruchem najwyżej kilka razy w trakcie jazdy, transfer takich danych nie powinien stanowić problemu technicznego.

Pewnym problemem może być natomiast zbieranie informacji o położeniach, prędkości i przyspieszeniu pojazdu (w pewnym sensie wystarczy przekazywać informacje o położeniu, gdyż chwilowa prędkość i przyspieszenie mogą być aproksymowane na podstawie odczytów kolejnych położań). W celu zapewnienia pełnych i wiarygodnych informacji o ruchu, informacje te powinny być zbierane z odpowiednią częstotliwością, idealnie gdyby można było je przekazywać do systemu zarządzania ruchem co najmniej raz na sekundę, choć w niektórych przypadkach może wystarczyć mniejsza rozdzielczość (np. raz na 5 sekund). W przypadku dużego miasta, w którym w godzinie szczytu może podróżować ponad 100 tysięcy pojazdów, oznacza to w praktyce przesyłanie w każdej sekundzie co najmniej kilku megabajtów danych. Przy odpowiednio zaprojektowanej infrastrukturze służącej do przesyłania danych (np. stacje pośrednie zlokalizowane przy głównych drogach i skrzyżowaniach, zbierające dane od pojazdów znajdujących się w pobliżu) powinno być to jednak technicznie wykonalne.

3.3. Przetwarzanie danych przez system zarządzania ruchem

Z uwagi na duży rozmiar danych zbieranych przez system zarządzania ruchem, ważnym zagadnieniem staje się ich przetwarzanie, przechowywanie i analiza. W przetwarzaniu danych związanych z lokalizacjami pojazdów przydatne mogą być narzędzia dedykowane dla dużych danych (ang. Big Data), np. Apache Spark ([22]). Narzędzia te są w stanie w bardzo sprawny i dobrze zorganizowany sposób rozpraszać obliczenia związane z przetwarzaniem dużych zbiorów danych na klaster obliczeniowy, korzystając m.in. z paradygmatu MapReduce ([23]). Tego typu podejścia sprawdziły się już w wielu zastosowaniach związanych z przetwarzaniem dużych zbiorów danych.

3.4. Problemy prawne

Poza problemami technicznymi związanymi z pobieraniem dużych ilości danych lokalizacyjnych z pojazdów w czasie rzeczywistym, pozostają jeszcze problemy prawne i etyczne związane z przetwarzaniem tego typu danych. Nie każdy bowiem może sobie życzyć, aby dane na temat jego lokalizacji, trasy i celu podróży były udostępniane do systemu zarządzania ruchem. Częściowo problem może zostać rozwiązany w sytuacji, gdy dane dotyczące lokalizacji pojazdu nie będą mogły zostać bezpośrednio powiązane z danym pojazdem, ani z osobami, które w tym pojeździe są (z punktu widzenia systemu zarządzania ruchem informacje te nie mają żadnego znaczenia i nie muszą być przesyłane, przydatny może być jedynie typ pojazdu oraz pewne jego parametry). Dodatkowo podróżni mogą być bardziej skłonni do dzielenia się informacjami na temat swojej lokalizacji i celu podróży, jeżeli będą mieli z tego powodu wyraźne korzyści. Bezpieczny i efektywny przejazd jest jedną z takich korzyści, kolejne to m.in. możliwość rekomendacji parkingów, atrakcji turystycznych, lokali gastronomicznych przy trasie i w pobliżu miejsca docelowego (połączona z możliwością rezerwacji miejsc parkingowych), możliwość

automatycznego powiadamiania odpowiednich służb w przypadku wykrycia na podstawie danych lokalizacyjnych awarii / wypadku, możliwość redukcji składki na ubezpieczenie samochodowe w przypadku bezpiecznej jazdy, możliwość otrzymania zniżek na paliwo i komunikację publiczną w zamian za przekazywanie danych na temat swojej lokalizacji. Nawet dane od kilku-kilkunastu procent uczestników ruchu mogą dać wystarczające informacje na temat czasów przejazdu, te informacje z kolei mogą służyć do aproksymacji liczby pojazdów, które przejeżdżają przez dany odcinek, np. na podstawie diagramu fundamentalnego zależności pomiędzy przepływem / liczbą pojazdów a czasem przejazdu ([24]).

Dodatkowo możliwości pojawią się wraz z nadejściem ery pojazdów autonomicznych i upowszechnieniem się modelu *Mobility on demand* [25]. Mieszkańcy miast mogą przestać posiadać pojazdy (przestanie być to opłacalny, z uwagi na ich cenę oraz koszty utrzymania), a zaczną je zamawiać w razie potrzeby, na podobnych zasadach jak obecnie taksówki (ale znacznie taniej, gdyż znikną koszty związane z kierowcą). Wtedy też nie będzie problemu z tym, że do systemu zarządzania ruchem przesyłane są dane, które mogą identyfikować pojazd, o ile nie będzie mógł on być zidentyfikowany z użytkownikiem.

Innym rozwiązaniem może być metoda *differential privacy* [26], w której celowo dodawany jest szum do danych, zachowując jednocześnie prywatność użytkownika, jak i dokładność danych zagregowanych. W przyszłości mogą pojawić się podobne matematyczne metody zapewniające zachowanie prywatności użytkownika oraz wystarczającą dokładność zbieranych od niego danych i przeprowadzanych obliczeń.

3.5. Optymalizacja ruchu drogowego

Zakładając, że system zarządzania ruchem w każdej chwili posiada informacje o położeniu, prędkości i trasie (aktualnej i planowanej) każdego pojazdu uczestniczącego w ruchu (lub od dostatecznie dużej liczby pojazdów, aby przeprowadzać wiarygodne, dokładne, mikroskopowe symulacje ruchu), pozostaje wciąż pytanie w jaki sposób przeszukiwać przestrzeń możliwych konfiguracji sygnalizacji świetlnej, aby znaleźć te, które rzeczywiście mogą być najlepsze i nie doprowadzą do powstania niepożądanych stanów ruchu.

Z pomocą mogą przyjść metaheurystyki, czyli algorytmy opisujące sposób przeszukiwania przestrzeni możliwych rozwiązań, aby znaleźć właściwe (akceptowalne) rozwiązanie danego problemu. Przykładami mogą być tu m.in. algorytmy genetyczne ([27]), metody Monte Carlo ([28]), algorytm Metropolis-Hastings ([29]). Wszystkie te metody w praktyce działają tym lepiej, im więcej konfiguracji z przestrzeni przeszukiwań są w stanie przetestować. Ponieważ test pojedynczej konfiguracji wymaga uruchomienia symulacji komputerowej z odpowiednio dobranymi parametrami, okazuje się, że skuteczność metaheurystyk może zależeć od posiadanej mocy obliczeniowej. Moc obliczeniowa jest skończona, a na dodatek w przypadku sterowania

ruchem online (np. adaptacja do sytuacji, w której był wypadek i zablokowana jest droga) jest pożądane, aby algorytmy znalazły dobre rozwiązania na tyle szybko, aby dało się je zastosować.

Do tego celu mogą przydać się obliczenia w klastrach o wysokiej wydajności (ang. HPC - *high-performance computing*, [30]), które posiadają wiele węzłów obliczeniowych, procesorów i rdzeni, znacznie większą pamięć i pojemność dyskową niż standardowe komputery. Ich moc obliczeniowa mierzona jest we FLOPS-ach (FLOPS - floating point operations per second - liczba operacji zmiennoprzecinkowych na sekundę) i w przypadku najpotężniejszych obecnie superkomputerów może sięgać kilkudziesięciu petaFLOPS ([31]). Komputery takie są jednak bardzo drogie i mogą pojawiać się problemy związane z ich utrzymaniem (awaria węzłów itp), dlatego w przyszłości dobrym rozwiązaniem może być przeprowadzanie niezbędnych obliczeń na wirtualnych klastrach, w chmurach obliczeniowych (np. Microsoft Azure [32]). Dodatkowo, przydatne mogą być specjalistyczne narzędzia do przetwarzania dużych zbiorów danych w klastrach (np. Apache Spark [22]).

Istotą proponowanego systemu zarządzania ruchem będą jednak algorytmy przeszukiwania przestrzeni możliwych konfiguracji sygnalizacji świetlnej oraz obliczania jakości danej konfiguracji. W tym pierwszym przypadku testowałem dotychczas algorytm genetyczny, który miał za zadanie znaleźć suboptymalne konfiguracje sygnalizacji świetlnej na mapie Warszawy, dla 2 wybranych obszarów: cała sieć drogowa w Warszawie oraz mniejszy obszar odpowiadający fragmentowi Starej Ochoty (15 skrzyżowań ze światłami). Dotychczasowe wyniki są bardzo obiecujące i opisane szczegółowo w pracach [33, 34]. Obecnie pracuję nad przyspieszeniem przeprowadzanych obliczeń poprzez wprowadzenie kolejnego poziomu zrównoleglenia oraz zastosowanie platformy Apache Spark, testuję również metody Monte Carlo.

W przypadku obliczania jakości konfiguracji sygnalizacji świetlnej pracuję nad metodami, które pozwolą zmniejszyć do minimum liczbę potrzebnych symulacji komputerowych. Badam m.in. zastosowanie sieci neuronowych do aproksymowania wartości funkcji oceny jakości konfiguracji. W tym przypadku mikroskopowe symulacje są potrzebne, aby przeprowadzić dokładne obliczenia funkcji oceny dla pewnego podzbioru konfiguracji (obecnie jest to ok. 100 000 konfiguracji), które stanowią zbiór treningowy dla sieci neuronowej. Eksperymenty pokazują, że to wystarczy, aby przybliżać wartość funkcji oceny z dokładnością rzędu 1%. Oznacza to, że wystarczy przeprowadzać mikroskopowe symulacje ruchu dla ok. 100 000 losowo wybranych konfiguracji sygnalizacji świetlnej, a następnie wytrenować sieć neuronową lub inny algorytm uczenia maszynowego, aby aproksymować wartość funkcji oceny jakości z bardzo dobrą dokładnością, bez przeprowadzania symulacji komputerowych, a więc również bardzo szybko (czas rzędu milisekund). Mając do dyspozycji odpowiednio dużą moc obliczeniową (np. klastr HPC lub chmura obliczeniowa), będzie można więc testować jednocześnie znacznie więcej konfiguracji niż w przypadku przeprowadzania jedynie symulacji komputerowej. Dodatkowo, jeżeli wspomniana sieć neuronowa będzie mogła zostać wytrenowana w trybie offline (np. na podstawie typowej macierzy podróży), a potem wydajnie modyfikowana w zależności od zaistniałej w ruchu drogowym sytuacji, to metody te mogą znaleźć zastosowanie w adaptacyjnym sterowaniu

sygnalizacją świetlną i działać w czasie rzeczywistym. Będą w stanie sprawdzić znacznie więcej konfiguracji sygnalizacji świetlnej i szacować ich jakość dokładniej niż istniejące obecnie systemy zarządzania ruchem.

Zaprezentowany system może sprawdzać się szczególnie dobrze w sytuacjach nietypowych (np. wyłączenie z ruchu głównej drogi), które mogą istotnie zmienić charakterystykę ruchu w mieście (zmiany nie będą jedynie niedużą fluktuacją), a także w przypadku dużego udziału w ruchu pojazdów autonomicznych i komunikujących się.

Bibliografia

- [1] Sidney Coordinated Adaptive Traffic System, <http://www.scats.com.au> .
- [2] Split, Cycle Offset Optimization Technique <http://www.scoot-utc.com> .
- [3] Real-time Hierarchical Optimizing Distributed Effective System, http://www.signalsystems.org.vt.edu/documents/Jan2001AnnualMeeting/PituMirchandaniRHODES_TRB2001.pdf
- [4] Mirchandani P., "RHODES and Next Generation RHODES", Panel ITS Meeting, 2011, <http://goo.gl/ykYqpE> .
- [5] Gartner N.H., Pooran, F.J., Andrews, C.M., "Implementation of the OPAC adaptive control strategy in a traffic signal network", IEEE Xplore Conference: Intelligent Transportation Systems, 2001. Proceedings. 2001 IEEE.
- [6] Problemy związane z pętlami indukcyjnymi: <http://gazetaolsztynska.pl/Korkuja-miasto--bo-nie-potrafia-wjechac-na-petle-indukcyjne,70458> .
- [7] Krumm J., "A Markov Model for Driver turn prediction.", SAE (Society of Automotive Engineers), 2008 World Congress, April 14-17, 2008, Detroit, MIUSA. Paper Number 2008-01-0195.
- [8] Xue A.Y., Zhang R., Zheng Y., Xie X., Huang J., Xu Z., "Destination Prediction by Sub-Trajectory Synthesis and Privacy Protection Against Such Prediction", in "IEEE International Conference on Data Engineering", str. 254-265.
- [9] Komunikacja V2I, Vehicle-to-infrastructure, rozwiązania proponowane przez Kapsch, <https://www.kapsch.net/ca/ktc/its-solutions/V2X-Cooperative-Systems> .
- [10] Pascale A., Hoang T.L., Nair R., "Characterization of network traffic processes under adaptive traffic control systems", in "Transportation Research Part C: Emerging Technologies", vol. 59, 2015, str. 240-357.
- [11] Program TRANSYT https://trlsoftware.co.uk/products/junction_signal_design/transyt .

- [12] Jaworski, P., "Cloud computing based adaptive traffic control and management", PhD Thesis. Coventry: Coventry University in collaboration with MIRA Ltd, 2013.
- [13] IEEE ICDM Contest: TomTom Traffic Prediction for Intelligent GPS Navigation, <http://tunedit.org/challenge/IEEE-ICDM-2010> .
- [14] Gora P., Son H. Nguyen, Szczuka M., Swietlicka J., Wojnarski M., Zeinalipour D., "IEEE ICDM 2010 Contest TomTom Traffic Prediction for Intelligent GPS Navigation", w "IEEE ICDM 2010 Workshops", 2010, str. 1372-1376, ISBN: 978-0-7695-4257-7.
- [15] Adamczyk M., Betliński P., Gora P., "Combined Bayesian Networks and Rough-Granular Approaches for Discovery of Process Models Based on Vehicular Traffic Simulation", w "Communications in Computer and Information Science", 2010, Volume 80, Part 2, str. 278-287, ISBN: 978-3-642-14054-9.
- [16] Kucharski R., "Rerouting phenomena modelling for unexpected events in Dynamic Traffic Assignment", PhD Thesis, Cracow University of Technology, 2015.
- [17] Wolfram S., "A New Kind of Science", Wolfram Media, Inc., 2002.
- [18] GNSS, Global Navigation Satellite System, <http://searchnetworking.techtarget.com/definition/GNSS> .
- [19] http://www.navtechgps.com/novatel_rtknav .
- [20] Dedicated short range communication, http://www.its.dot.gov/DSRC/dsrc_faq.htm.
- [21] Kenney J.B., "Dedicated Short-Range Communications (DSRC) Standards in the United States", w "PROCEEDINGS OF THE IEEE 99(7)": str. 1162 – 1182.
- [22] Apache Spark – strona oficjalna, <http://spark.apache.org> .
- [23] Dean J., Ghemawat S., "MapReduce: simplified data processing on large clusters", w "Communications of the ACM", Vol. 51, Issue 1, 2008, str. 107-113.
- [24] "75 Years of the Fundamental Diagram for Traffic Flow Theory", w "Transportation Research Circular No. E-C149", 2011.
- [25] Pavone M., "Autonomous Mobility-on-Demand Systems for Future Urban Mobility", "Autonomes Fahren", 2015, str. 399-416.
- [26] Dwork C., McSherry F., Nissim K., Smith A., "Calibrating Noise to Sensitivity in Private Data Analysis", w "Theory of Cryptography", Vol. 3876, Lecture Notes in Computer Science, 2006, str. 265-284.
- [27] Mitchell M., "An Introduction to Genetic Algorithms", MIT Press Cambridge, MA, USA, 1996.

- [28] Metropolis, N., "The beginning of the Monte Carlo method", Los Alamos Science, 1987, str. 125-130.
- [29] Hastings, W.K., "Monte Carlo Sampling Methods Using Markov Chains and Their Applications". Biometrika **57** (1): str. 97–109, 1970.
- [30] High-Performance Computing, HPC, <http://insidehpc.com/hpc-basic-training/what-is-hpc> .
- [31] Lista najpotężniejszych superkomputerów, <http://www.top500.org/statistics/sublist>
- [32] Microsoft Azure: <https://azure.microsoft.com> .
- [33] Gora P., Pardel P., "Application of Genetic Algorithms and High-Performance Computing to the Traffic Signal Setting Problem", Concurrency, Specification & Programming 1, 2015, str. 146-157.
- [34] Gora P., "A genetic algorithm approach to optimization of vehicular traffic in cities by means of configuring traffic lights", w "Emerging Intelligent Technologies in Industry", 2011, str. 1-10.